

1. Quel est le rôle principal de HDFS dans l'architecture Hadoop ?

- A) Traiter les données
 - B) Gérer les ressources des machines
 - C) Stocker les données de manière distribuée
 - D) Analyser les données en temps réel
-

2. Dans Hadoop, que fait YARN ?

- A) Répartir les données entre les nœuds du cluster
 - B) Gérer les ressources du cluster et planifier les tâches
 - C) Diviser les tâches en sous-tâches
 - D) Exécuter des calculs sur les données
-

3. Quel composant d'Hadoop est responsable de la gestion des erreurs et de la tolérance aux pannes ?

- A) MapReduce
 - B) HDFS
 - C) YARN
 - D) Hive
-

4. Quelle est la principale différence entre le traitement Map et Reduce dans le framework MapReduce ?

- A) Map trie les données et Reduce les analyse
 - B) Map divise les tâches et Reduce les compile
 - C) Map génère des paires clé/valeur et Reduce les combine
 - D) Map traite les erreurs et Reduce gère la tolérance aux pannes
-

5. Que signifie le terme "Shuffle & Sort" dans le contexte de MapReduce ?

- A) Regrouper les données par clé avant de les traiter
- B) Répartir les données dans plusieurs clusters
- C) Optimiser la vitesse de traitement des données

D) Analyser les données en fonction de leur fréquence

6. Quelle est la taille par défaut d'un bloc dans HDFS ?

- A) 16 Mo
 - B) 64 Mo
 - C) 128 Mo
 - D) 1 Go
-

7. Dans un cluster Hadoop, combien de fois les données sont-elles répliquées par défaut ?

- A) Une fois
 - B) Deux fois
 - C) Trois fois
 - D) Cinq fois
-

8. Quel outil Hadoop est principalement utilisé pour effectuer des requêtes SQL sur des données stockées dans HDFS ?

- A) Pig
 - B) Hive
 - C) Sqoop
 - D) HBase
-

9. Quelle technologie est la plus appropriée pour des analyses de données en temps réel dans l'écosystème Hadoop ?

- A) HBase
 - B) Flume
 - C) Pig
 - D) Hive
-

10. Dans un cluster Hadoop, qu'est-ce qui peut provoquer une panne générale du système ?

- A) La panne d'un DataNode
- B) La panne d'un NameNode

- C) La saturation de l'espace disque
 - D) L'échec de la tâche Map
-

11. Quel type de base de données est HBase ?

- A) Relationnelle
 - B) NoSQL
 - C) Graph
 - D) Document
-

12. Quel est le but principal de l'outil Sqoop dans l'écosystème Hadoop ?

- A) Analyser les logs
 - B) Migrer les données d'une base de données relationnelle vers Hadoop
 - C) Effectuer des calculs sur les données
 - D) Visualiser les résultats des analyses
-

13. Quelle est la principale limitation d'Hadoop pour les petits travaux ?

- A) Consommation élevée de mémoire
 - B) Inefficacité pour les analyses simples
 - C) Complexité dans la configuration
 - D) Manque de sécurité
-

14. Quel est le rôle de Flume dans Hadoop ?

- A) Collecter des logs et les transférer dans HDFS
 - B) Répliquer les données entre les nœuds du cluster
 - C) Effectuer des requêtes SQL sur les données
 - D) Analyser les résultats des tâches MapReduce
-

15. Quelle technique est utilisée par Hadoop pour garantir la tolérance aux pannes ?

- A) Réplication des données
 - B) Compression des données
 - C) Partitionnement des données
 - D) Allocation dynamique des ressources
-

16. Comment Hadoop gère-t-il l'évolutivité ?

- A) En réduisant la taille des blocs de données
 - B) En ajoutant de nouveaux nœuds au cluster
 - C) En augmentant la capacité de stockage d'un DataNode
 - D) En améliorant les performances de MapReduce
-

17. Dans un fichier CSV contenant des ventes, comment la tâche MAP pourrait-elle être effectuée ?

- A) Trier les ventes par produit
 - B) Extraire des paires clé/valeur comme ("ProduitA", 20\$)
 - C) Calculer la somme des ventes par produit
 - D) Analyser la tendance des ventes sur le temps
-

18. Dans un exemple de comptage de mots, quelle serait la sortie de la phase MAP ?

- A) La liste triée des mots
 - B) La somme des occurrences des mots
 - C) Une paire clé/valeur pour chaque mot avec sa fréquence
 - D) Une liste de mots uniques
-

19. Quel est l'impact d'un échec du NameNode sur un cluster Hadoop ?

- A) Les tâches Map échoueraient
 - B) Les DataNodes ne pourraient plus stocker de données
 - C) Le cluster entier serait arrêté
 - D) Les pannes de données seraient ignorées
-

20. Quels types de données peuvent être traités par Hadoop ?

- A) Uniquement des données structurées
- B) Uniquement des données non structurées
- C) Tous types de données, structurées et non structurées
- D) Uniquement des données numériques

21. Quel outil de l'écosystème Hadoop est utilisé pour effectuer des analyses complexes sans nécessiter de programmation ?

- A) Hive
 - B) HBase
 - C) Pig
 - D) Flume
-

22. Quelle est l'importance de YARN dans la gestion des tâches MapReduce ?

- A) Il divise les données en petits morceaux
 - B) Il alloue des ressources et planifie l'exécution des tâches
 - C) Il réplique les données pour éviter la perte
 - D) Il effectue des calculs sur les données
-

23. Que fait l'outil Hive dans l'écosystème Hadoop ?

- A) Permet de gérer les ressources des nœuds
 - B) Permet d'exécuter des requêtes SQL sur les données stockées dans HDFS
 - C) Permet de créer des modèles de machine learning
 - D) Permet de gérer les logs
-

24. Quelle est la principale caractéristique de MapReduce dans Hadoop ?

- A) Analyser des données en temps réel
 - B) Gérer les ressources d'un cluster
 - C) Diviser un travail en deux étapes : Map et Reduce
 - D) Gérer les erreurs dans les DataNodes
-

25. Dans le cadre de l'analyse de texte avec Hadoop, quel serait le résultat final de l'étape Reduce ?

- A) La liste complète des mots du texte
- B) La fréquence totale de chaque mot dans le texte

- C) Le texte transformé en paires clé/valeur
 - D) Le regroupement des mots par longueur
-

26. Dans un environnement Hadoop, quel est le rôle d'Ambari ?

- A) Collecter des logs
 - B) Gérer les tâches MapReduce
 - C) Surveiller l'état du cluster et des services
 - D) Créer des bases de données NoSQL
-

27. Quelle est la méthode utilisée par Hadoop pour éviter les pertes de données en cas de panne ?

- A) Compression des données
 - B) Réplication des données
 - C) Utilisation de systèmes RAID
 - D) Archivage des données
-

28. Quel est l'objectif principal de l'outil Pig dans Hadoop ?

- A) Analyser des données avec un langage de programmation simple
 - B) Permettre la visualisation des résultats des analyses
 - C) Gérer les nœuds du cluster
 - D) Effectuer des calculs complexes sur les données
-

29. Qu'est-ce qu'un cluster Hadoop ?

- A) Un seul serveur de stockage de données
 - B) Un réseau de plusieurs ordinateurs travaillant ensemble
 - C) Une seule machine de traitement de données
 - D) Un composant logiciel pour analyser les données
-

30. Qu'est-ce qu'une "clé" dans le cadre du traitement MapReduce ?

- A) Un identifiant unique de chaque paire de données
- B) La donnée brute à traiter
- C) Un indicateur du type de calcul à effectuer
- D) La sortie du processus de tri

Quelles sont les caractéristiques principales d'un "cluster" Hadoop ?

- a) Traitement en temps réel, stockage local
- b) Stockage distribué, traitement parallèle
- c) Traitement séquentiel, stockage local
- d) Aucune des réponses ci-dessus
- **Quel est l'objectif principal de YARN dans Hadoop ?**
 - a) Diviser les données en blocs
 - b) Gérer les ressources du cluster et planifier les tâches
 - c) Répliquer les données
 - d) Gérer la sécurité du cluster
- **Dans MapReduce, quelle fonction est responsable de l'agrégation des résultats ?**
 - a) Map
 - b) Shuffle
 - c) Reduce
 - d) Sort
- **Le HDFS se distingue par quel aspect principal ?**
 - a) Il effectue un traitement parallèle des données
 - b) Il est utilisé pour le calcul de valeurs sur de petites données
 - c) Il divise les données en blocs et les réplique pour la tolérance aux pannes
 - d) Il exécute des calculs en temps réel
- **Quelle est la taille typique d'un bloc de données dans HDFS ?**
 - a) 8 Mo

- b) 64 Mo
- c) 128 Mo
- d) 256 Mo

• **Quel composant d'Hadoop est responsable de la répartition des tâches entre les différents nœuds ?**

- a) HDFS
- b) MapReduce
- c) YARN
- d) Hive

• **Comment MapReduce gère-t-il la répartition des données pour le traitement parallèle ?**

- a) Il divise les données en partitions basées sur des règles personnalisées
- b) Il assigne chaque tâche à un nœud spécifique sans diviser les données
- c) Il divise les données en blocs égaux, indépendamment de leur contenu
- d) Il divise les données en morceaux, les envoie aux nœuds et les regroupe avant l'agrégation

• **Quel est le rôle principal de NameNode dans HDFS ?**

- a) Gérer le stockage des données dans le cluster
- b) Effectuer la réplication des blocs de données
- c) Surveiller la santé du cluster
- d) Gérer l'accès aux données stockées

• **Pourquoi Hadoop utilise-t-il la réplication des blocs dans HDFS ?**

- a) Pour améliorer les performances de traitement
- b) Pour garantir la sécurité et la tolérance aux pannes
- c) Pour faciliter la compression des données
- d) Pour réduire les coûts de stockage

• **Le composant "Shuffle" dans MapReduce est utilisé pour :**

- a) Effectuer la cartographie des données
- b) Regrouper les données par clé avant l'étape Reduce
- c) Trier les données par valeur
- d) Diviser les données en blocs

• **Quel est l'un des inconvénients majeurs de Hadoop pour des tâches simples ?**

- a) Les données sont traitées trop rapidement
- b) L'architecture distribuée le rend inefficace pour de petites quantités de données
- c) Il nécessite des machines coûteuses pour fonctionner
- d) Il ne peut pas gérer de données non structurées

• **Quel est le principal avantage de l'utilisation de YARN dans un cluster Hadoop ?**

- a) Il permet de réduire la consommation d'espace de stockage
- b) Il optimise l'utilisation des ressources et garantit une gestion efficace des tâches
- c) Il fournit des outils de traitement des données en temps réel
- d) Il simplifie l'interface utilisateur

• **Dans Hadoop, quel est l'objectif de Pig ?**

- a) Optimiser les performances des tâches MapReduce
- b) Offrir une interface SQL pour analyser les données
- c) Analyser des données avec un langage de script simple
- d) Répliquer les données pour la sauvegarde

• **Le nombre de répliques par défaut d'un bloc dans HDFS est :**

- a) 1
- b) 2

- c) 3
- d) 4

• **Quel est l'impact d'une panne de NameNode dans un cluster Hadoop ?**

- a) Les données sont immédiatement perdues
- b) Le traitement des tâches se poursuit normalement sans impact
- c) L'ensemble du cluster devient inactif jusqu'à la restauration de NameNode
- d) Les performances de traitement sont considérablement améliorées

• **Dans le cadre de l'analyse de texte avec MapReduce, le processus "Shuffle & Sort" consiste principalement à :**

- a) Trier les paires clé/valeur par ordre alphabétique
- b) Grouper les paires de même clé avant l'agrégation
- c) Supprimer les doublons dans les données
- d) Appliquer des fonctions mathématiques aux données

• **Quel outil Hadoop est principalement utilisé pour interagir avec des bases de données relationnelles comme MySQL ?**

- a) Sqoop
- b) Hive
- c) HBase
- d) Flume

• **Qu'est-ce que Flume dans l'écosystème Hadoop ?**

- a) Un outil de gestion des tâches de MapReduce
- b) Un collecteur et un transporteur de données, principalement pour les logs
- c) Un système de stockage de données
- d) Un moteur de traitement en temps réel

• **Dans le cadre de MapReduce, quel est l'objectif de la fonction "Map" ?**

- a) Combiner les résultats partiels en un seul résultat final
- b) Diviser les données en blocs de taille égale
- c) Analyser chaque morceau de données et générer des paires clé/valeur
- d) Trier les données avant de les envoyer aux nœuds
- **Le principal défi de Hadoop en termes de gestion des données est :**
 - a) La gestion de la réplication des données
 - b) La lenteur du traitement des données volumineuses
 - c) La gestion de la sécurité des données
 - d) La complexité d'utilisation pour les petites entreprises
- **La principale raison pour laquelle Hadoop est utilisé avec des ordinateurs simples et bon marché est :**
 - a) Réduire la consommation d'énergie
 - b) Limiter les coûts de stockage
 - c) Maximiser l'efficacité du stockage et du calcul
 - d) Minimiser les coûts d'infrastructure tout en permettant une évolutivité
- **HBase est un outil Hadoop principalement utilisé pour :**
 - a) Réaliser des requêtes SQL sur des données non structurées
 - b) Effectuer des traitements en temps réel
 - c) Fournir une base de données NoSQL pour des recherches rapides
 - d) Effectuer des traitements de données en batch
- **Quel est l'effet de l'augmentation de la taille des blocs dans HDFS ?**
 - a) Amélioration de la performance de lecture, mais utilisation accrue d'espace de stockage
 - b) Réduction de la complexité du traitement, mais augmentation du temps de traitement
 - c) Diminution de la sécurité des données
 - d) Aucune modification significative
- **Pourquoi le parallélisme est-il crucial dans Hadoop ?**
 - a) Il permet un traitement séquentiel plus rapide des données
 - b) Il aide à économiser de l'espace disque
 - c) Il permet d'analyser simultanément de grandes quantités de données, accélérant le traitement
 - d) Il simplifie l'interface de programmation
- **Dans un environnement Hadoop, un "node" se réfère à :**
 - a) Un bloc de données stocké
 - b) Un point de calcul ou de stockage dans le cluster
 - c) Une tâche MapReduce spécifique
 - d) Une machine qui surveille l'état du cluster
- **Hadoop MapReduce est particulièrement adapté pour :**
 - a) Le traitement en temps réel de petites quantités de données
 - b) La gestion des tâches interactives avec des résultats immédiats
 - c) Le traitement par lot de données massives et non structurées
 - d) Les applications nécessitant une faible latence
- **Quel est le rôle principal de Hive dans l'écosystème Hadoop ?**
 - a) Analyser des données en utilisant des scripts Python
 - b) Fournir une interface SQL pour interroger et manipuler des données stockées dans HDFS
 - c) Gérer les clusters de calcul Hadoop

- d) Optimiser les performances des tâches MapReduce
- **Quel composant d'Hadoop est utilisé pour surveiller la santé du cluster et ses performances ?**
 - a) HDFS
 - b) Ambari
 - c) Flume
 - d) Pig
- **Le but de l'algorithme de "MapReduce" est de :**
 - a) Créer des blocs de données pour une meilleure organisation
 - b) Analyser de grandes quantités de données et obtenir un résultat final après regroupement
 - c) Sauvegarder les résultats d'un traitement dans HDFS
 - d) Assurer la réplication des données pour plus de sécurité
- **Quel est l'impact principal de la mise en place d'un système de réplication dans HDFS ?**
 - a) Meilleure gestion des tâches MapReduce
 - b) Moins de performances lors du traitement des données
 - c) Une meilleure tolérance aux pannes
 - d) Réduction de la taille des blocs de données